

PHÁT HIỆN GIÁ TRỊ NGOẠI BIÊN TRONG PHÂN TÍCH DỮ LIỆU ĐA BIẾN

Lý thuyết, Tiêu chuẩn Khi-bình phương, Quy trình và Minh họa

Phân tích Thống kê Đa biến

Ngày 4 tháng 10 năm 2026

1 Phần 1: Lý thuyết và các công thức toán học

Phát hiện giá trị ngoại biên trong không gian đa biến dựa trên việc đo lường khoảng cách từ từng quan sát tới tâm của tập dữ liệu, có tính đến sự tương quan và độ phân tán giữa các biến.

1.1 Véc-tơ trung bình mẫu và Ma trận hiệp phương sai mẫu

Giả sử dữ liệu gồm n quan sát trên p biến ngẫu nhiên, kí hiệu véc-tơ quan sát thứ j là $\mathbf{x}_j = [x_{j1}, x_{j2}, \dots, x_{jp}]'$, $j = 1, 2, \dots, n$.

- Véc-tơ trung bình mẫu ($\bar{\mathbf{x}}$):

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix} \quad (1)$$

trong đó $\bar{x}_k = \frac{1}{n} \sum_{j=1}^n x_{jk}$ với $k = 1, \dots, p$.

- Ma trận hiệp phương sai mẫu (S):

$$S = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}})(\mathbf{x}_j - \bar{\mathbf{x}})' \quad (2)$$

Ma trận S có kích thước $p \times p$, với phần tử trên đường chéo s_{kk} là phương sai mẫu của biến thứ k , và s_{ik} ($i \neq k$) là hiệp phương sai giữa biến thứ i và biến thứ k .

1.2 Giá trị chuẩn hóa đơn biến (z_{jk})

Để phát hiện các giá trị ngoại biên trên từng biến đơn lẻ, ta tính giá trị chuẩn hóa z -score:

$$z_{jk} = \frac{x_{jk} - \bar{x}_k}{\sqrt{s_{kk}}}, \quad j = 1, \dots, n; \quad k = 1, \dots, p \quad (3)$$

Một quan sát x_{jk} thường được coi là giá trị ngoại biên đơn biến nếu $|z_{jk}| > 3$ (hoặc vượt quá 3.5 tùy kích thước mẫu).

1.3 Bình phương khoảng cách Mahalanobis (d_j^2)

Khoảng cách Mahalanobis bình phương đo lường khoảng cách tổng quát từ điểm dữ liệu $\mathbf{x}_j$ tới véc-tơ trung bình $\bar{\mathbf{x}}$ trong không gian p chiều:

$$d_j^2 = (\mathbf{x}_j - \bar{\mathbf{x}})' S^{-1} (\mathbf{x}_j - \bar{\mathbf{x}}), \quad j = 1, 2, \dots, n \quad (4)$$

trong đó S^{-1} là ma trận nghịch đảo của ma trận hiệp phương sai mẫu S .

1.4 Tiêu chuẩn phân phối Khi-bình phương (χ_p^2) và Cách xác định

1.4.1 Bản chất lý thuyết

Nếu véc-tơ ngẫu nhiên $\mathbf{X} = [X_1, X_2, \dots, X_p]'$ tuân theo phân phối chuẩn p -chiều $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, khoảng cách thống kê bình phương từ $\mathbf{X}$ tới $\boldsymbol{\mu}$ tuân theo phân phối Khi-bình phương với p bậc tự do:

$$(\mathbf{X} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) \sim \chi_p^2 \quad (5)$$

Khi thay các tham số tổng thể bằng véc-tơ trung bình mẫu $\bar{\mathbf{x}}$ và ma trận hiệp phương sai mẫu S , với cỡ mẫu n và $n - p$ đủ lớn ($n \geq 25 - 30$), phân phối chọn mẫu của khoảng cách Mahalanobis bình phương d_j^2 sẽ xấp xỉ phân phối χ_p^2 với p bậc tự do.

1.4.2 Quy tắc kiểm định phát hiện giá trị ngoại biên

- **Mức ý nghĩa α :** Chọn một mức xác suất cực trị rất nhỏ (ví dụ $\alpha = 0.005$ hoặc 0.01) đại diện cho xác suất cực kỳ hiếm gặp của một điểm dữ liệu bình thường.
- **Giá trị tới hạn $\chi_p^2(\alpha)$:** Là giá trị thỏa mãn diện tích phần đuôi trên của phân phối χ_p^2 đúng bằng α :

$$P(D^2 > \chi_p^2(\alpha)) = \alpha \iff P(D^2 \leq \chi_p^2(\alpha)) = 1 - \alpha \quad (6)$$

- **Tiêu chuẩn kết luận:** Một quan sát $\mathbf{x}_j$ bị coi là **giá trị ngoại biên đa biến** nếu:

$$d_j^2 > \chi_p^2(\alpha) \quad (7)$$

1.4.3 Các phương pháp tính giá trị tới hạn $\chi_p^2(\alpha)$

1. **Tra bảng phân phối Khi-bình phương:** Tra tại hàng ứng với bậc tự do $df = p$ và cột diện tích đuôi trên α .
2. **Sử dụng phần mềm (Python/R):** Tính hàm phân vị ngược (PPF - Percent Point Function):

$$\chi_p^2(\alpha) = \text{PPF}_{\chi^2}(1 - \alpha, df = p) \quad (8)$$

3. **Giải phương trình tích phân tích lũy (CDF):** Tìm x thỏa mãn $1 - F(x; p) = \alpha$, trong đó $F(x; p) = \frac{\gamma(p/2, x/2)}{\Gamma(p/2)}$ là hàm phân phối tích lũy của χ_p^2 .

2 Phần 2: Các bước phát hiện giá trị ngoại biên & Minh họa Ví dụ 5.3.1

2.1 Các bước tổng quát phát hiện giá trị ngoại biên

Quy trình phát hiện giá trị ngoại biên đa biến gồm 4 bước cơ bản:

1. **Bước 1 (Trực quan hóa đơn biến):** Lập biểu đồ điểm (dot plot) hoặc biểu đồ hộp (boxplot) cho từng biến để tìm các quan sát lệch chuẩn rõ rệt.
2. **Bước 2 (Trực quan hóa hai biến):** Lập biểu đồ tán xạ (scatter plot) cho từng cặp biến để quan sát cấu trúc đường đồng mức elip và phát hiện các điểm nằm ngoài elip.
3. **Bước 3 (Kiểm tra giá trị chuẩn hóa z_{jk}):** Tính $z_{jk} = (x_{jk} - \bar{x}_k)/\sqrt{s_{kk}}$. Kiểm tra các giá trị $|z_{jk}| > 3$ hoặc $|z_{jk}| > 3.5$.
4. **Bước 4 (Tính khoảng cách Mahalanobis d_j^2):** Tính $d_j^2 = (\mathbf{x}_j - \bar{\mathbf{x}})'S^{-1}(\mathbf{x}_j - \bar{\mathbf{x}})$. So sánh d_j^2 với ngưỡng tối hạn $\chi_p^2(\alpha)$ và lập biểu đồ Chi-square plot.

2.2 Đề bài Ví dụ 5.3.1 (Phát hiện giá trị ngoại biên trong dữ liệu về gỗ xẻ)

Đề bài (Ví dụ 5.3.1): Cho tập dữ liệu gồm $n = 30$ mẫu vật gỗ xẻ, mỗi mẫu vật được đo lường bởi $p = 4$ chỉ số độ cứng khác nhau:

- x_1 : Đo độ cứng bằng cách gửi sóng xung kích xuống tấm gỗ.
- x_2 : Đo độ cứng trong khi cho tấm gỗ rung động.
- x_3 : Kết quả đo độ cứng từ thử nghiệm tĩnh thứ nhất.
- x_4 : Kết quả đo độ cứng từ thử nghiệm tĩnh thứ hai.

Yêu cầu:

1. Tính các giá trị chuẩn hóa $z_{jk} = \frac{x_{jk} - \bar{x}_k}{\sqrt{s_{kk}}}$ ($k = 1, 2, 3, 4; j = 1, 2, \dots, 30$) cho từng quan sát.
2. Tính bình phương khoảng cách Mahalanobis $d_j^2 = (\mathbf{x}_j - \bar{\mathbf{x}})'S^{-1}(\mathbf{x}_j - \bar{\mathbf{x}})$.
3. Đánh giá và xác định các quan sát ngoại biên đa biến dựa trên giá trị tới hạn Khi-bình phương $\chi_4^2(0.005) = 14.86$.

2.3 Minh họa lời giải cho Ví dụ 5.3.1

2.3.1 Tính toán véc-tơ trung bình và ma trận hiệp phương sai

Từ $n = 30$ quan sát đa biến, véc-tơ trung bình mẫu $\bar{\mathbf{x}}$ và ma trận hiệp phương sai mẫu S được tính toán như sau:

$$\bar{\mathbf{x}} = \begin{bmatrix} 1906.10 \\ 1749.53 \\ 1509.13 \\ 1724.97 \end{bmatrix}, \quad S = \begin{bmatrix} 105616.30 & 94613.53 & 87289.71 & 94230.73 \\ 94613.53 & 101510.12 & 76137.10 & 81064.36 \\ 87289.71 & 76137.10 & 91917.09 & 90352.38 \\ 94230.73 & 81064.36 & 90352.38 & 104227.96 \end{bmatrix}$$

2.3.2 Giải thích chi tiết giá trị tới hạn $\chi_4^2(0.005) \approx 14.86$

Trong Ví dụ 5.3.1, giá trị 14.86 được xác định dựa vào:

- **Bậc tự do** ($p = 4$): Do dữ liệu thu thập 4 chỉ số độ cứng (x_1, x_2, x_3, x_4).
- **Mức ý nghĩa** ($\alpha = 0.005$): Đại diện cho 0.5% xác suất ở đuôi cực trị (tương ứng với phân vị 99.5%).

Chứng minh qua giải phương trình tích phân: Đối với phân phối χ^2 với bậc tự do chẵn $p = 4$, hàm phân phối tích lũy CDF $F(x; 4)$ có công thức tường minh:

$$F(x; 4) = 1 - e^{-x/2} \left(1 + \frac{x}{2}\right) \quad (9)$$

Diện tích phần đuôi trên $\alpha = 0.005$ tương ứng với phương trình:

$$1 - F(x; 4) = 0.005 \iff e^{-x/2} \left(1 + \frac{x}{2}\right) = 0.005 \quad (10)$$

Thay $x = 14.86026$ vào phương trình:

- $\frac{x}{2} = 7.43013 \implies 1 + \frac{x}{2} = 8.43013$
- $e^{-7.43013} \approx 0.00059312$
- Về trái: $8.43013 \times 0.00059312 \approx 0.005000$


Phương trình cho nghiệm chính xác $x = 14.860259\dots$, khi làm tròn đến 2 chữ số thập phân thu được **14.86**.

2.3.3 Bảng kết quả tính toán

Bảng 1: Kết quả tính toán giá trị chuẩn hóa z_{jk} và khoảng cách d_j^2 cho các mẫu tiêu biểu

Mẫu	x_1	x_2	x_3	x_4	z_1	z_2	z_3	z_4	d_j^2
1	1889	1651	1561	1778	-0.1	-0.3	0.2	0.2	0.60
2	2403	2048	2087	2197	1.5	0.9	1.9	1.5	5.48
9	2983	2794	2412	2581	3.3	3.3	3.0	2.7	12.26
16	1954	2149	1180	1281	0.1	1.3	-1.1	-1.4	16.85
30	1490	1382	1214	1284	-1.3	-1.2	-1.0	-1.4	2.58

2.3.4 Biểu đồ tán xạ (Scatter Plots) phân tích vị trí các giá trị ngoại biên



Hình 1: Biểu đồ tán xạ thể hiện vị trí các quan sát trong không gian hai chiều. Mẫu 16 có xu hướng lệch khỏi mô hình chung giữa các phép đo tĩnh và động.

2.3.5 Nhận xét chi tiết kết quả phân tích

- **Mẫu vật 16 (Specimen 16):** Có $d_{16}^2 = 16.85 > \chi_4^2(0.005) = 14.86$. Do đó, **Mẫu 16 chính là giá trị ngoại biên đa biến**. Mặc dù tất cả các giá trị chuẩn hóa đơn biến ($z_1 = 0.1, z_2 = 1.3, z_3 = -1.1, z_4 = -1.4$) đều thuộc phạm vi bình thường ($|z_{16,k}| \leq 1.4$), Mẫu 16 bị coi là bất thường trong không gian 4 chiều do hai phép đo động (x_1, x_2) cao hơn trung bình trong khi hai phép đo tĩnh (x_3, x_4) lại thấp.
- **Mẫu vật 9 (Specimen 9):** Có $d_9^2 = 12.26$ và các giá trị z -score đơn biến đều rất lớn ($z_1 = 3.3, z_2 = 3.3, z_3 = 3.0$), cho thấy đây là một thanh gỗ rất cứng ở mọi phép thử.